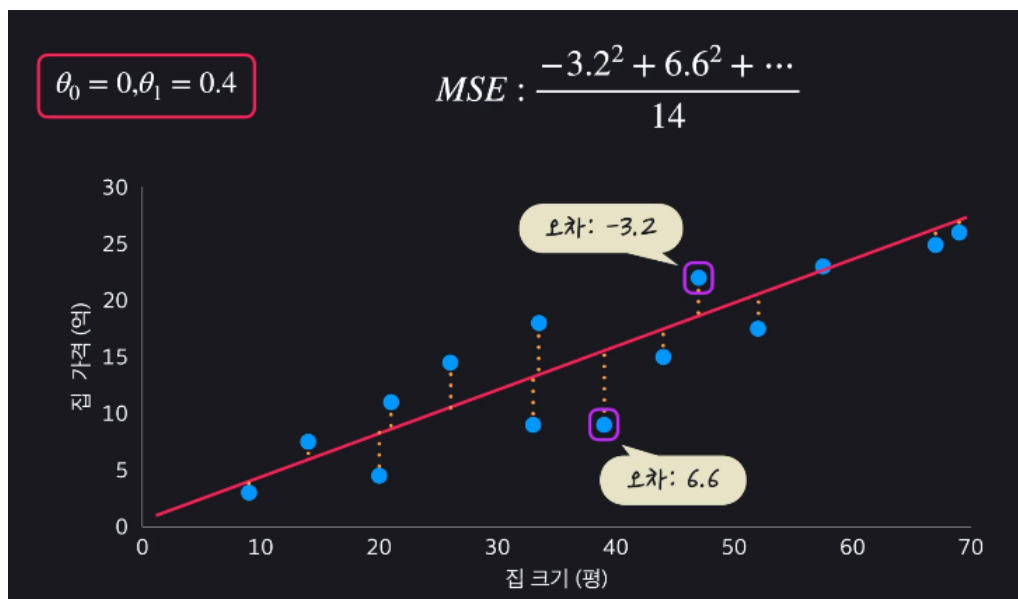


Linear Regression

MSE (평균 제곱 오차)

- 선형회귀에서는 데이터에 가장 적절한 하나의 선인 “최적선”을 찾아야 함
- 최적선을 찾기 위해 여러 함수를 시도함 (=가설 함수)
- MSE는 가설함수를 평가하기 위한 방법
- 모든 오차를 양수로 통일하고, 더 큰 오차를 부각시킴



Regularized Method (정규화 방법론)

: 선형회귀 계수 (weight)에 제약 조건을 추가해서 모형의 과적합을 막는 것

- 계수의 크기를 제한하는 방법이 일반적
- 회귀분석은 잔차 (실제값과 예측값의 차이)를 이용하여 검증을 진행함

LASSO (L1)

Least Absolute Shrinkage and Selection Operator의 줄임말

: 가중치의 **절대값의 합**을 최소화하는 것을 추가 제약 조건으로 가진 회귀모형

$$w = \arg \min_w \left(\sum_{i=1}^N e_i^2 + \lambda \sum_{j=1}^M |w_j| \right)$$

- 모든 값들의 최소값인 0으로 빠르게 수렴시켜 상관성이 없는 독립변수들을 0으로 바꿈 \Rightarrow 종속변수에 영향을 적게 주는 독립변수 제거 가능
- 다중공선성의 제거에 효과적

Ridge(L2)

sum of weights을 최소화하는 것을 추가 제약 조건으로 가진 회귀모형

$$w = \arg \min_w \left(\sum_{i=1}^N e_i^2 + \lambda \sum_{j=1}^M w_j^2 \right)$$

λ =기존의 잔차 제곱합에 추가 제약 조건의 비중을 조절하는 하이퍼파라미터 = 정규화 정도

- 0이면 일반적인 선형 회귀모델이 됨
- 커지면 정규화 정도가 커지고, w 값이 작아짐
- “1보다 큰 숫자들이 1에 가깝게 바꾸려고 함”

⇒ 독립변수 값들의 크기를 조정해서 좀 더 현실성 있는 데이터로 만들어줌

Elastic Net (L1+L2)

: 가중치의 절대값의 합과 제곱합을 동시에 제약 조건으로 가지는 모형

$$w = \arg \min_w \left(\sum_{i=1}^N e_i^2 + \lambda_1 \sum_{j=1}^M |w_j| + \lambda_2 \sum_{j=1}^M w_j^2 \right)$$

- L1xL2 정규화. L1, L2 정규화 항 각각을 더해줌

Norm

$$\|A\|_p = \left(\sum_{i=1}^N \sum_{j=1}^M |a_{ij}|^p \right)^{1/p}$$

: 벡터의 길이 or 크기를 나타냄. 행렬에서 크기를 구하는 방법 중 하나

- $p=1$ 이면 L1 Norm, $p=2$ 이면 L2 Norm

Frobenius Norm (프로베니우스 놈)

: L2 Norm을 행렬로 확장한 버전